Uma rede neural dentro da BitDogLab

O que fiz com sons cardíacos,
TinyML e um RP2040

Leandro Alves dos Santos
Introdução à Inteligência Artificial • UNEB

Minha pergunta

Uma rede pequena consegue executar na placa e produzir uma classificação útil para este conjunto de gravações?

Eu medi duas coisas: as previsões e o custo de executar.

O objetivo é estudar execução local em poucos recursos

Training no PC. Inference na placa

TRAINING

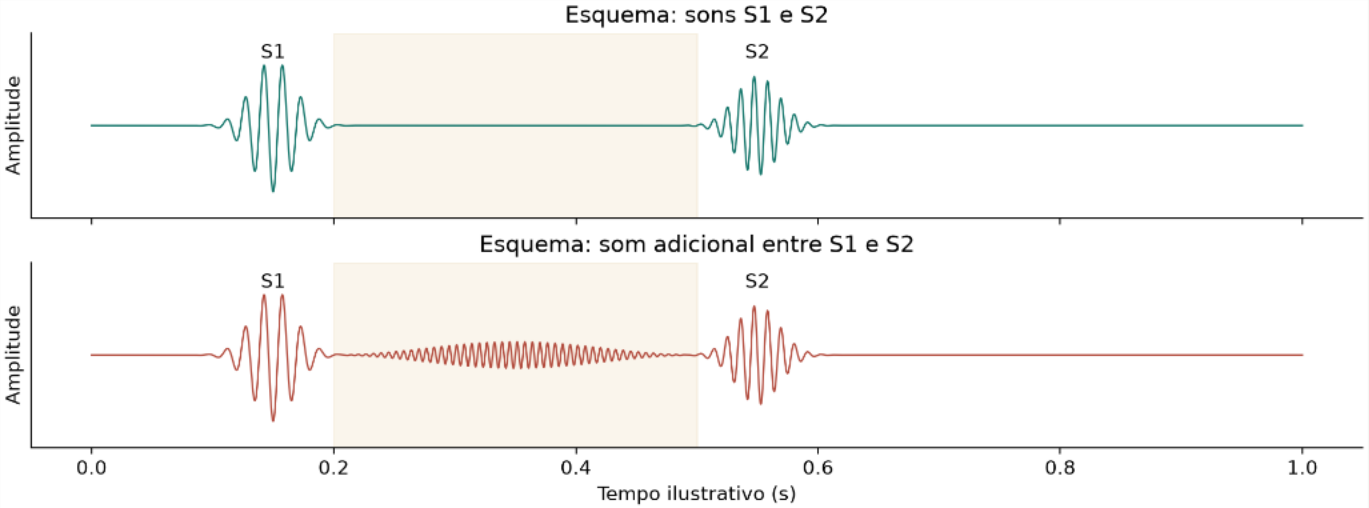
Áudios com rótulos
Ajuste dos weights
RTX 5050 no Arch/WSL

INFERENCE

Weights congelados
Novo áudio entra
Scores e uma decisão saem

O PC também faz inference. A placa não faz training neste projeto

O que chamo de “com sopro”?



Um heart murmur é um som adicional associado ao fluxo de sangue.

Esquema didático. As classes não equivalem a saudável/doente

Primeiro ouvir. Depois pedir a previsão

Áudio 1

Grupo rotulado Absent
39043_AV • validation

Áudio 2

Grupo rotulado Present
49627_AV • validation

O painel inclui seis exemplos reais.

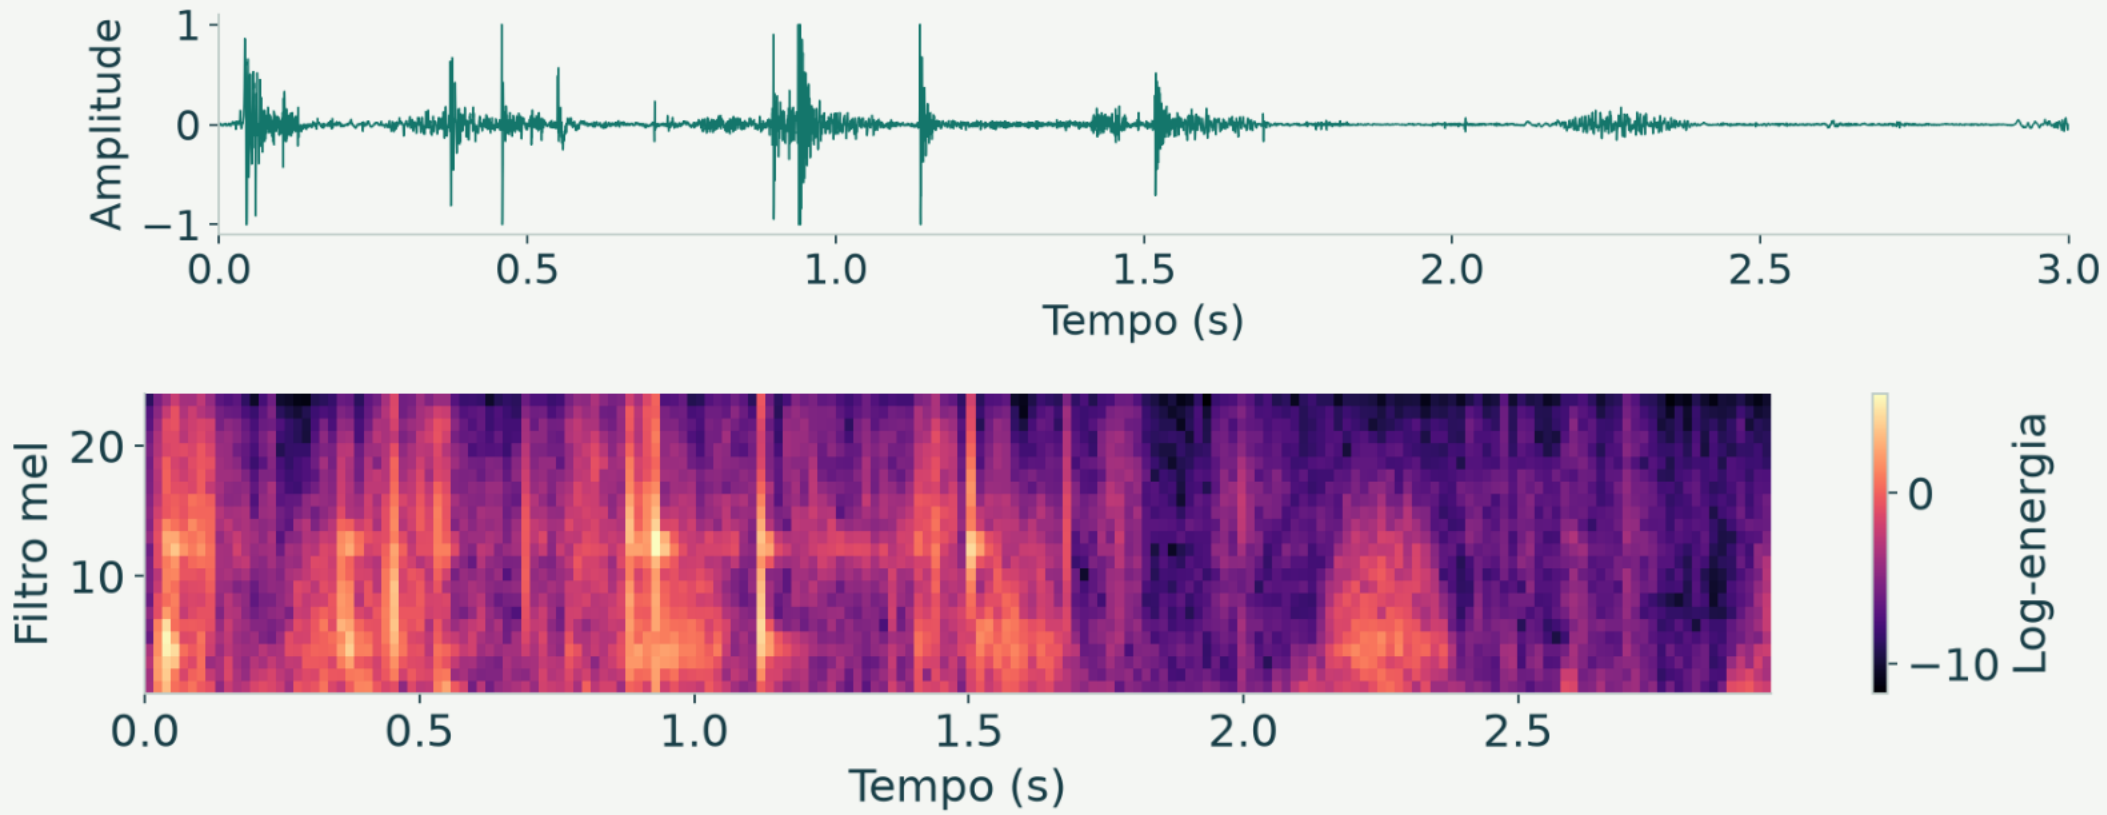
Um trecho pode não conter um sopro audível, mesmo herdando um rótulo Present

Antes do training, separei os grupos

Partição	Grupos	Present / Absent	Recordings
Training	568	109 / 459	2.066
Validation	122	24 / 98	439
Test	122	24 / 98	471

Os grupos são separados antes de criar as windows. Unknown foi excluído

Do som aos números



Waveform e log-MFE reais de uma window de validation

Quantas entradas a rede recebe?

3 s × 4.000 samples/s = 12.000 samples

Hann window: 128 samples
Frame hop: 64 samples

1 + floor((12.000 − 128) / 64) = 186 frames

186 frames × 24 Mel bands = 4.464 features por window

O MFE resume a energia em frequências

Hann → FFT → power spectrum
24 Mel filters → log-energy → normalization

$$E(t, b) = \Sigma\, H(b, k) \times |X(t, k)|^2$$

$$z(t, b) = [\ln(\max(E(t, b), 10^{-6})) - \mu(b)] / \sigma(b)$$

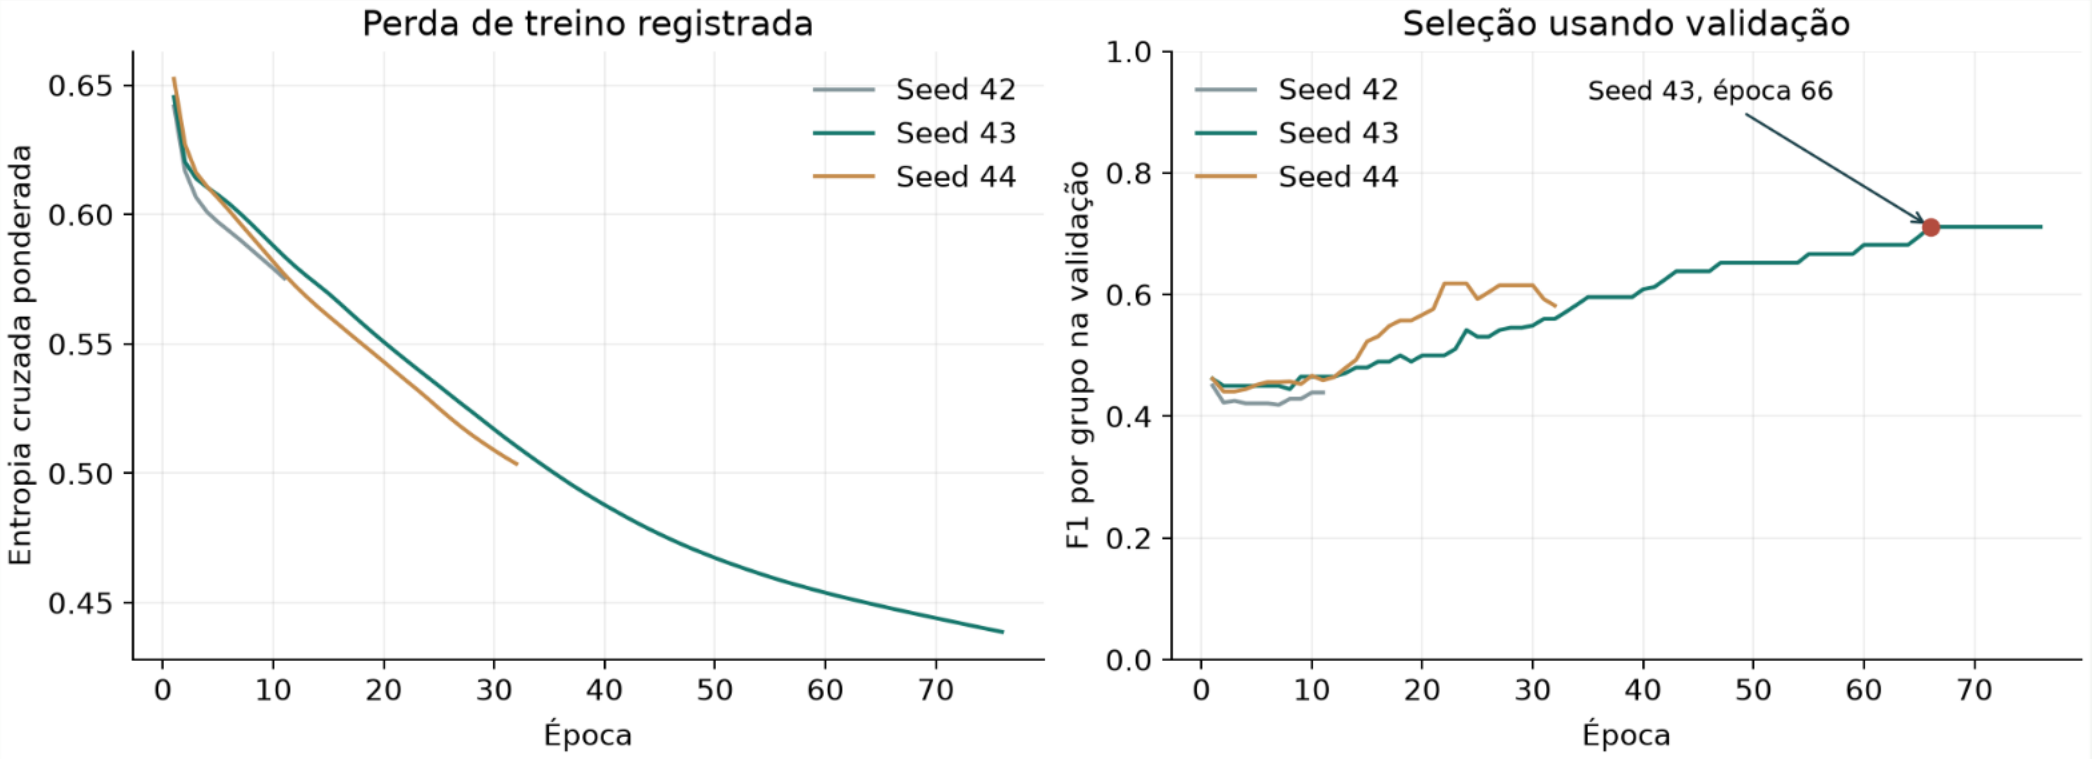
Mean e standard deviation vieram apenas de training

Minha CNN tem 1.282 parâmetros

Layer	Conta dos parameters	Total
Conv2D 3×3, 8 channels	(3 × 3 × 1 + 1) × 8	80
Conv2D 3×3, 16 channels	(3 × 3 × 8 + 1) × 16	1.168
Dense, 2 classes	(16 + 1) × 2	34
Total	80 + 1.168 + 34	1.282

ReLU, MaxPool e Global Average Pooling não acrescentam parameters neste modelo

Como o training escolheu os weights



Seed 43, epoch 66, escolhida por validation F1 = 0,711

O que é INT8?

Float32

32 bits por valor

INT8

8 bits por valor
256 códigos: −128 a 127

A rede aproxima valores reais usando scale e zero-point.

Weights e activations menores; bias e accumulators podem usar INT32

Uma conta com a scale real do modelo

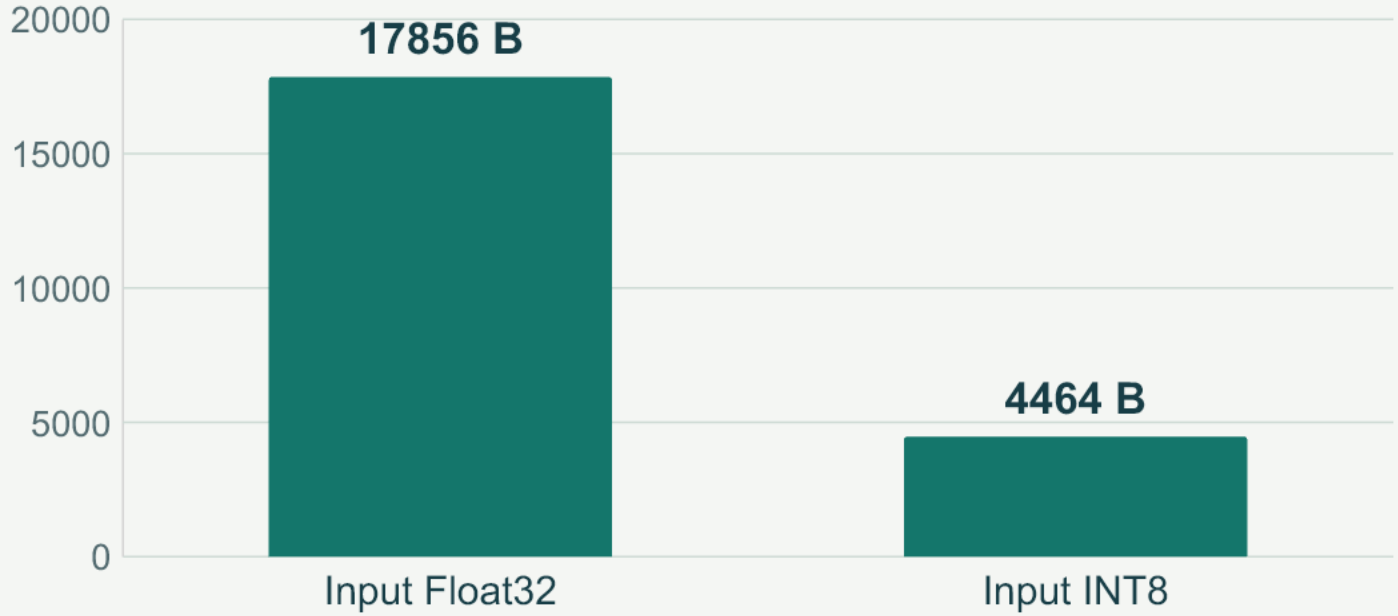
scale = 0,04310979694 **zero-point = −38**

Para z = 1:
q = round(1 / scale) − 38 = −15
z reconstruído = (−15 + 38) × scale ≈ 0,9915

O arredondamento introduziu um erro de ≈ −0,0085.

q recebe saturation no intervalo INT8; zero real é representado por q = −38

O que economizo e o que perco



4.464 features
17.856 → 4.464 bytes

Há rounding
e saturation

É a conta do tensor de input. O arquivo completo INT8 tem 5.264 bytes

Da window à decisão de um grupo

Window scores

mean por recording → maximum entre recordings do grupo

Score do grupo ≥ threshold → Present

INT8 threshold = 0,734675480769, escolhido em validation

Como conferi a execução na placa

PC envia o mesmo PCM por USB

RP2040 calcula MFE + TFLite Micro inference

PC registra scores, tempos e hashes

Test completo: 6.512 windows • 471 recordings • 122 grupos

O que obtive no test set

Execução	F1	Recall	Accuracy
Always Absent	0,000	0,0%	80,3%
Float32 CNN / PC	0,694	70,8%	87,7%
INT8 / PC optimized	0,680	70,8%	86,9%
INT8 / PC reference	0,694	70,8%	87,7%
INT8 / RP2040	0,694	70,8%	87,7%

Resultados por grupo, com as mesmas 122 unidades de test

Onde a rede errou

Rótulo do grupo	Previsto Present	Previsto Absent
Present	17 TP	7 FN
Absent	8 FP	90 TN

A placa identificou 17 dos 24 positivos. Perdeu 7.

Como calculei F1 e Recall

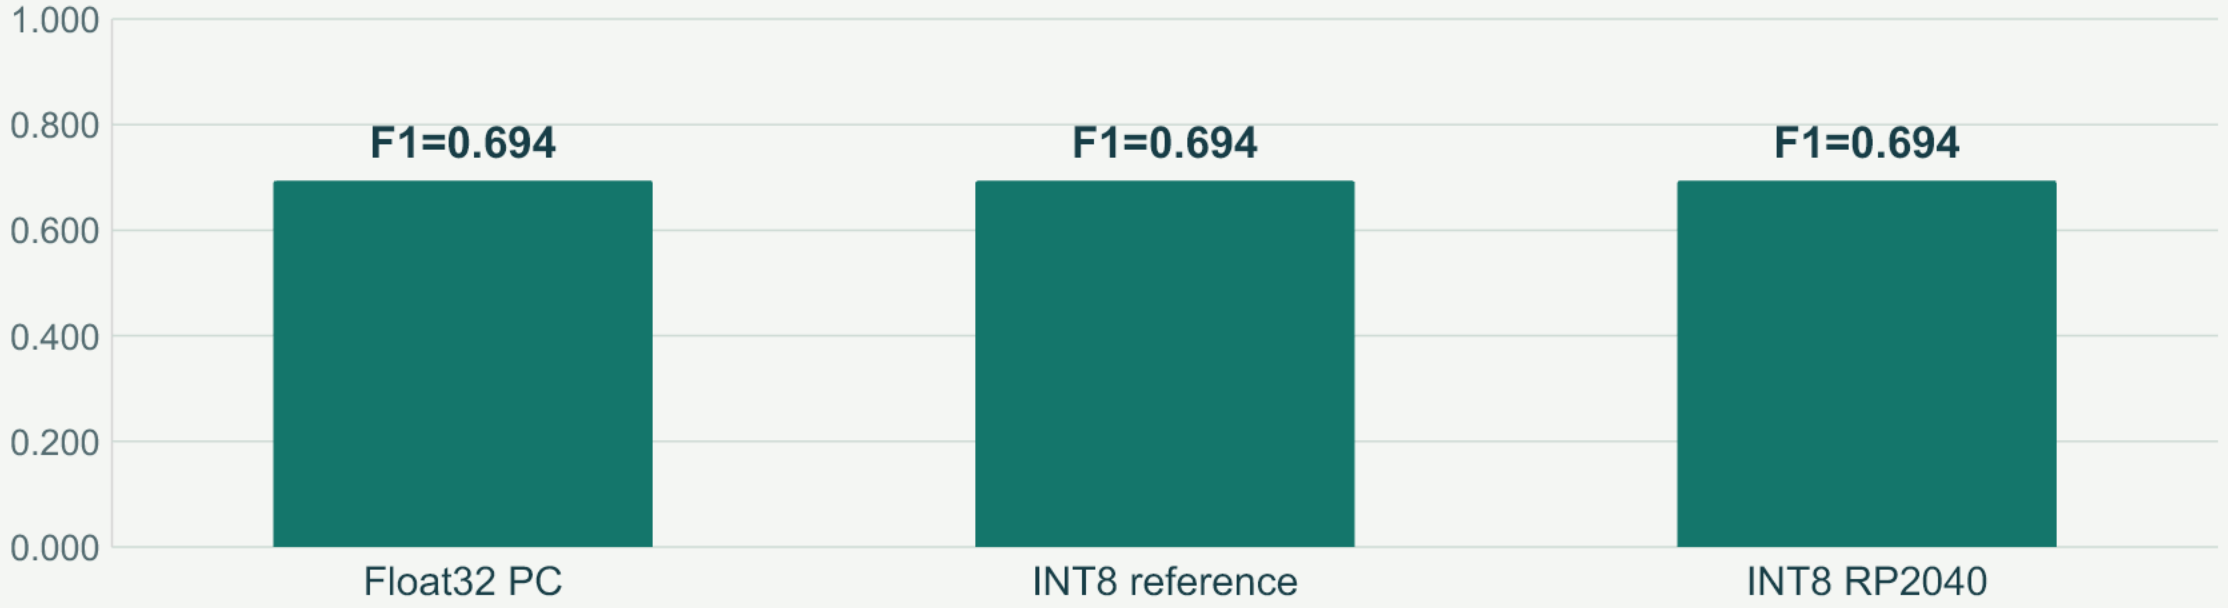
Recall = 17 / (17 + 7) = 70,8%

F1 = 2 × 17 / (2 × 17 + 8 + 7) ≈ 0,694

Accuracy = (17 + 90) / 122 = 87,7%

Always Absent teria Accuracy de 80,3%, mas Recall zero

A mesma resposta pode ser um bom sinal



Mesmas decisões por grupo não significam processamento bit a bit idêntico

O tempo é outra parte da resposta

Etapa	PC CPU (ms)	RP2040 (ms)
MFE + normalization	0,237	1.006,545
Inference	2,425	311,868
Combinado	2,687	1.318,421

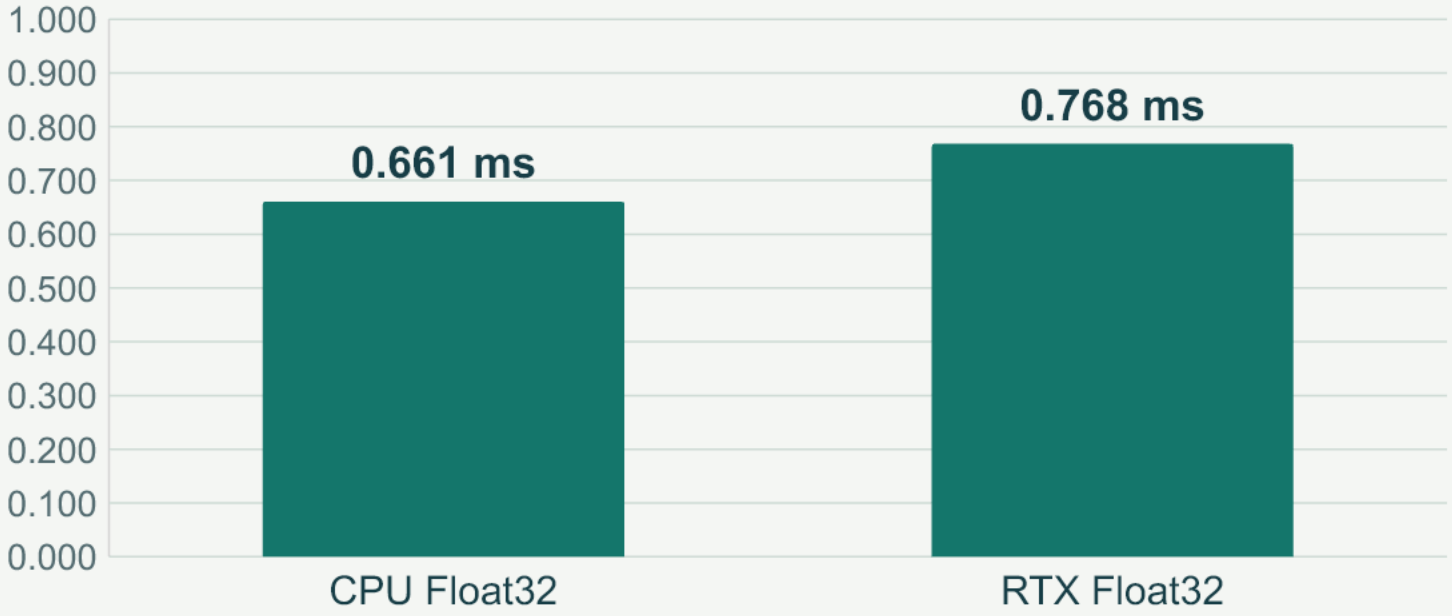
Histórico: mesmas 100 validation windows • CPU de uma thread • medianas

O novo benchmark mostrou diferenças

Execução	Inference (ms)	MFE + net (ms)
CPU Float32 / TensorFlow	0,661	0,836
RTX Float32 / TensorFlow	0,768	0,956
CPU Float32 / reference	1,347	1,509
CPU INT8 / reference	1,932	2,113
RP2040 INT8 / demo V3	312,077	1.322,608

Novo: 100 validation windows × 3 • batch size 1 • medianas de uma sessão

Nesta CNN, a RTX não reduziu a latência

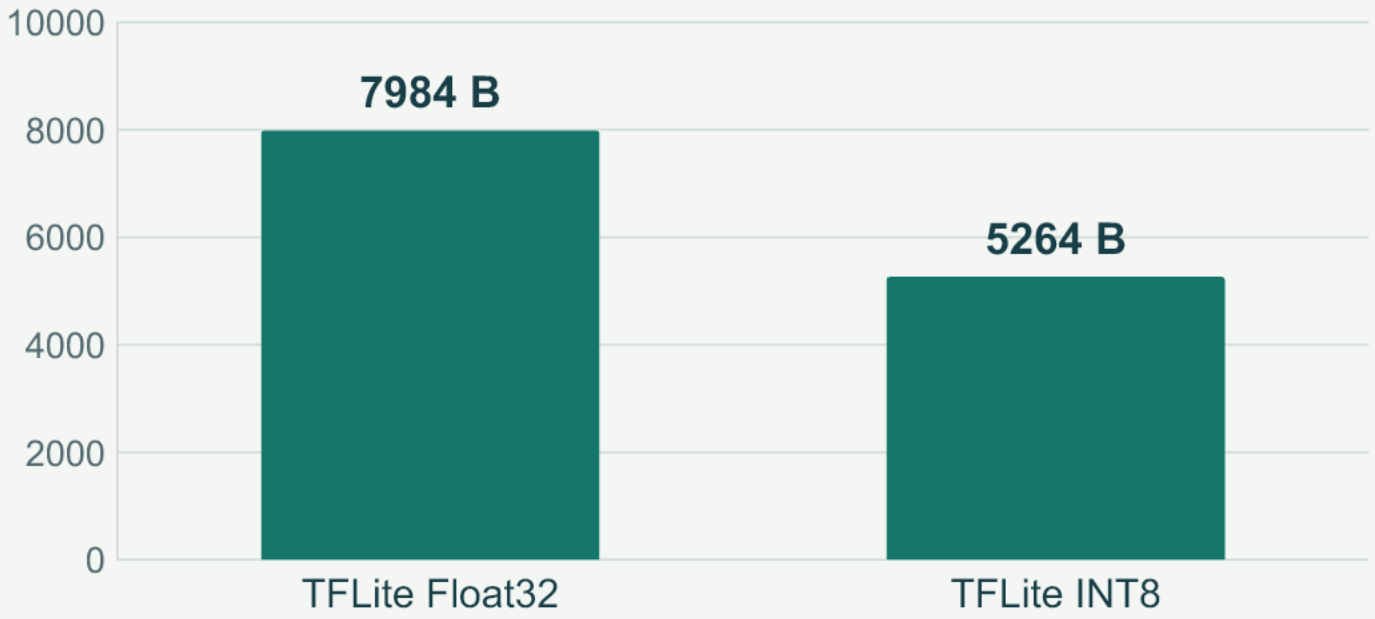


batch size = 1

Dispatch e sincronização também têm custo.

Resultado desta sessão. Não é uma comparação de training ou de throughput em batches grandes

INT8 reduziu o arquivo em 34,1%



7.984 → 5.264 bytes

CPU reference:
1,347 → 1,932 ms

2 de 100 windows mudaram de classe.

Mesmo resolver. Scores comparados com o mesmo threshold; isso não é patient accuracy

O modelo é pequeno. O programa usa mais

Quantidade medida no firmware científico	Bytes
Modelo INT8	5.264
Firmware flash image	189.408
Static main SRAM span	186.224
Tensor arena capacity, já incluída	147.456
Runtime peak RAM	Não medido

Modelo, firmware e RAM são medidas diferentes; não somar a arena duas vezes

Demonstração: o mesmo WAV nos dois

1. Ouvir o áudio e olhar a waveform

2. Executar no PC e observar o score

3. Enviar o mesmo PCM à placa e comparar

Seis exemplos de validation. Microfone é um experimento separado

O que consegui e o que ainda falta

Consegui executar e medir o modelo no RP2040 com o test set completo.

Ainda preciso investigar os erros,
as diferenças numéricas e a aquisição real.

TinyML foi viável neste replay digital; isso não estabelece validade clínica

Referências e onde reproduzir

Oliveira et al. • CirCor / IEEE JBHI, 2022
DOI 10.1109/JBHI.2021.3137048 • Dataset 10.13026/tshs-mw03

Reyna et al. • PhysioNet Challenge 2022 / PLOS, 2023
DOI 10.1371/journal.pdig.0000324

David et al. • TensorFlow Lite Micro / MLSys, 2021
Google AI Edge • LiteRT 8-bit quantization specification
American Heart Association • Heart Murmurs

github.com/Lawtrel/bitdoglab-heart-tinyml