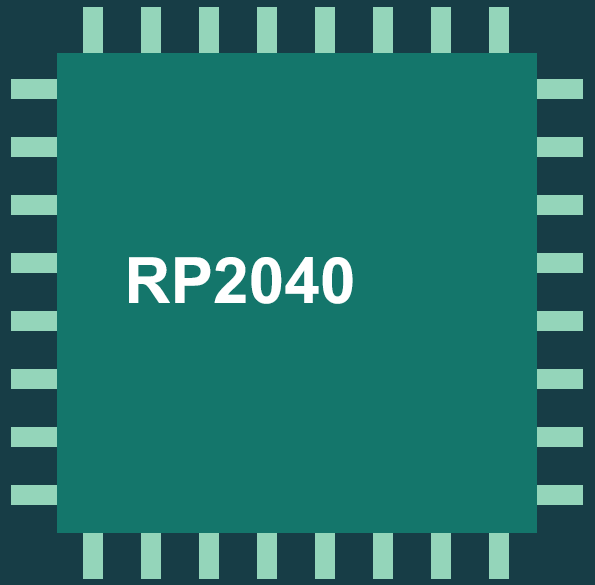
TinyML na BitDogLab

Classificação de sopros cardíacos com uma rede neural no RP2040



Inferência local

Leandro Alves dos Santos
UNEB, Engenharia de Software

Treinamento e inferência

NO COMPUTADOR

Gravações com rótulos

A rede ajusta seus pesos

RTX usada no treinamento

NA BITDOGLAB

Pesos já aprendidos

Áudio novo entra na rede

Uma classificação é calculada

TinyML permite executar inferência local em dispositivos com recursos limitados

O que a rede classifica

Sopro presente

Um som adicional percebido durante a ausculta

Sopro ausente

Previsão de ausência desse padrão na entrada analisada

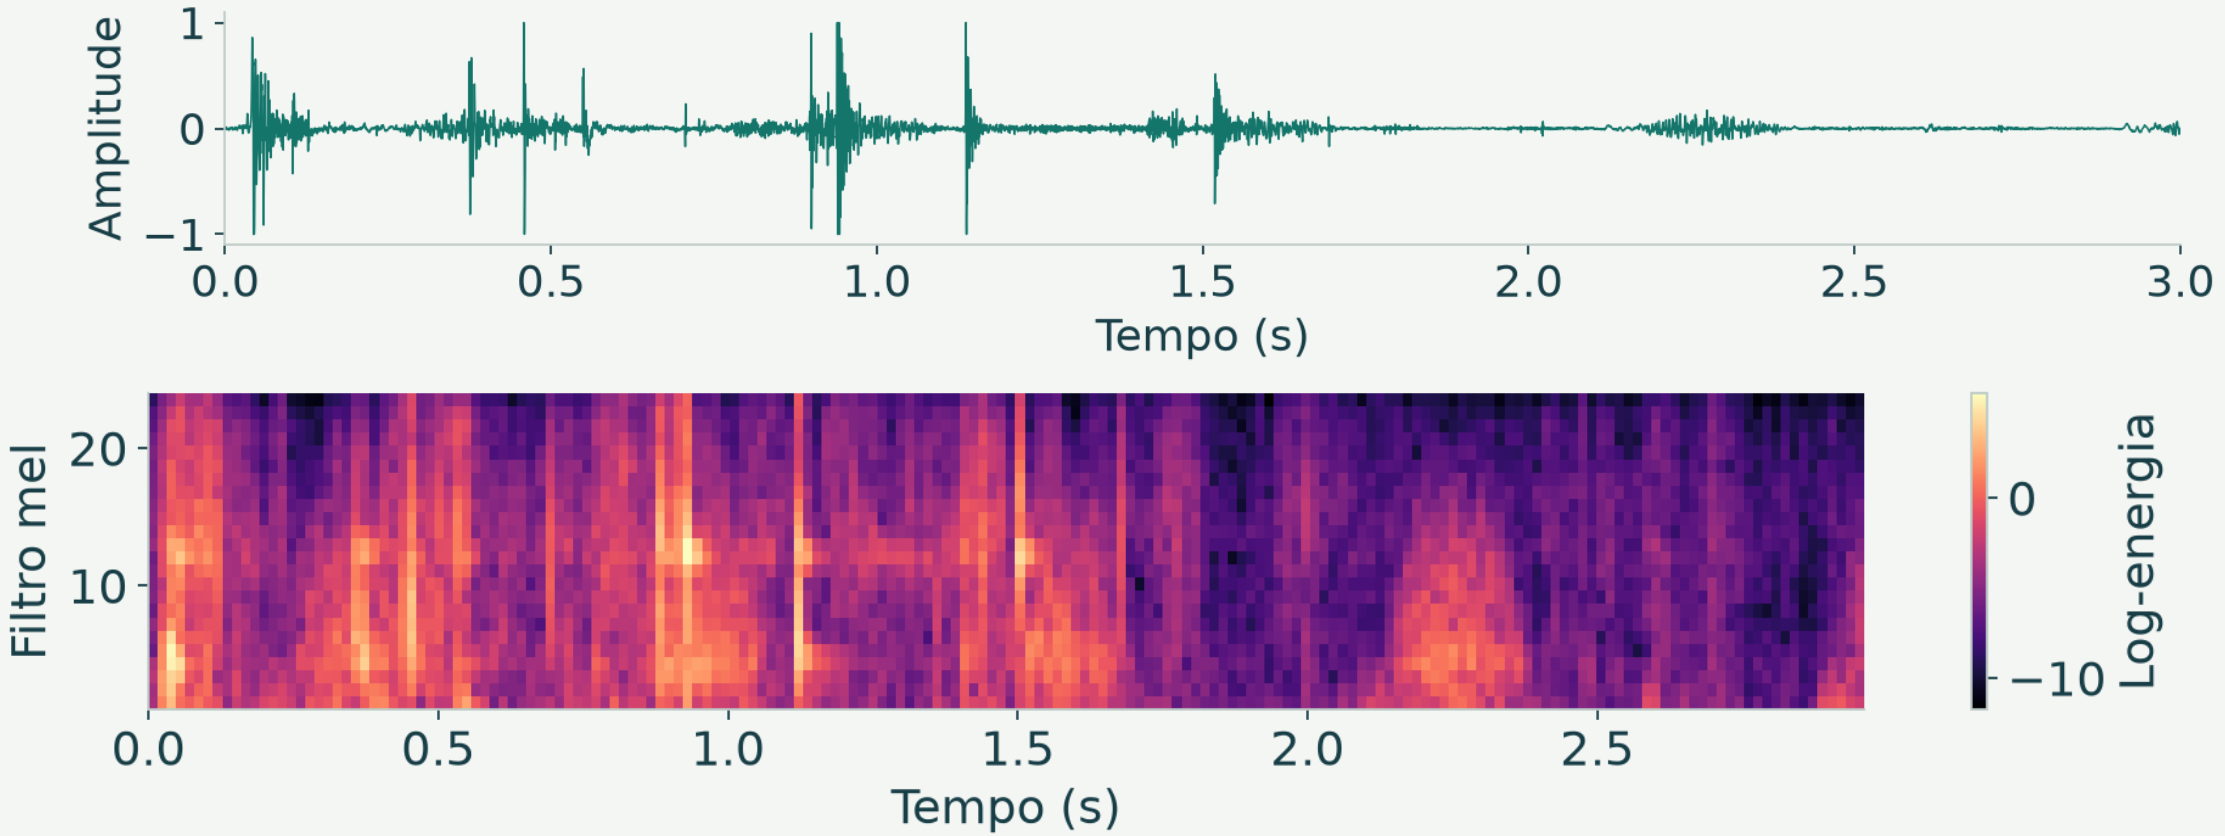
A saída é uma previsão. O modelo não identifica doenças nem detecta qualquer batimento

Dados e divisão por grupo

Partição	Grupos	Gravações
Treino	568	2.066
Validação	122	439
Teste	122	471

CirCor 1.0.3, Present/Absent, Unknown excluído, identidades vinculadas permanecem juntas

O áudio vira uma representação MFE



Uma CNN pequena para o RP2040

MFE

186 × 24

Conv + pool

8 filtros

Conv + pool

16 filtros

Saída

2 classes

1.282 parâmetros

A rede aprende padrões na representação do áudio e gera um escore para a classe presente

Quantização e implantação

FLOAT32

Representação usada
durante o treinamento

4 bytes por número

INT8

Representação de 8 bits
para a inferência embarcada

1 byte por número

Modelo exportado: 5.264 bytes

Como o experimento foi avaliado

6.512

janelas de teste na placa

122

grupos para as métricas finais

Replay digital controlado, modelo e limiar congelados, métricas agregadas por grupo

Desempenho no PC e na placa

Execução	F1	Recall	Acurácia
PC float	0,694	70,8%	87,7%
PC INT8 otimizado	0,680	70,8%	86,9%
PC INT8 referência	0,694	70,8%	87,7%
BitDogLab INT8	0,694	70,8%	87,7%

122 grupos no teste, uma decisão difere entre a placa e o host otimizado

Os erros também fazem parte do resultado

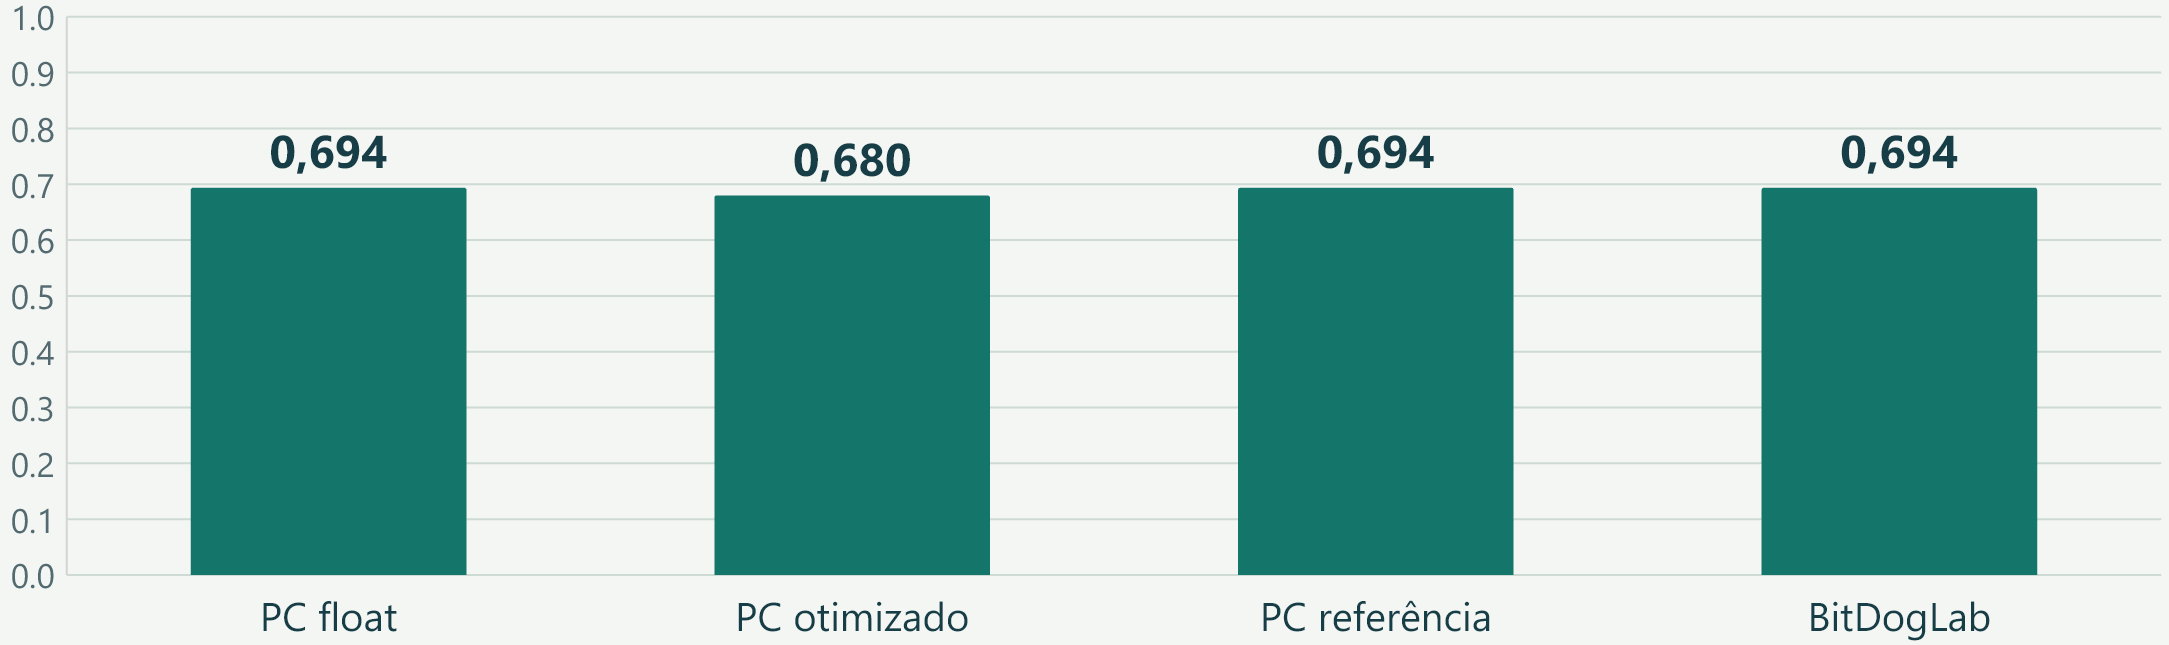
Rótulo de referência	Presente	Ausente
Presente	17	7
Ausente	8	90

7 de 24

positivos foram classificados como sem sopro

Um resultado negativo da rede não exclui sopro ou doença

F1 entre implementações



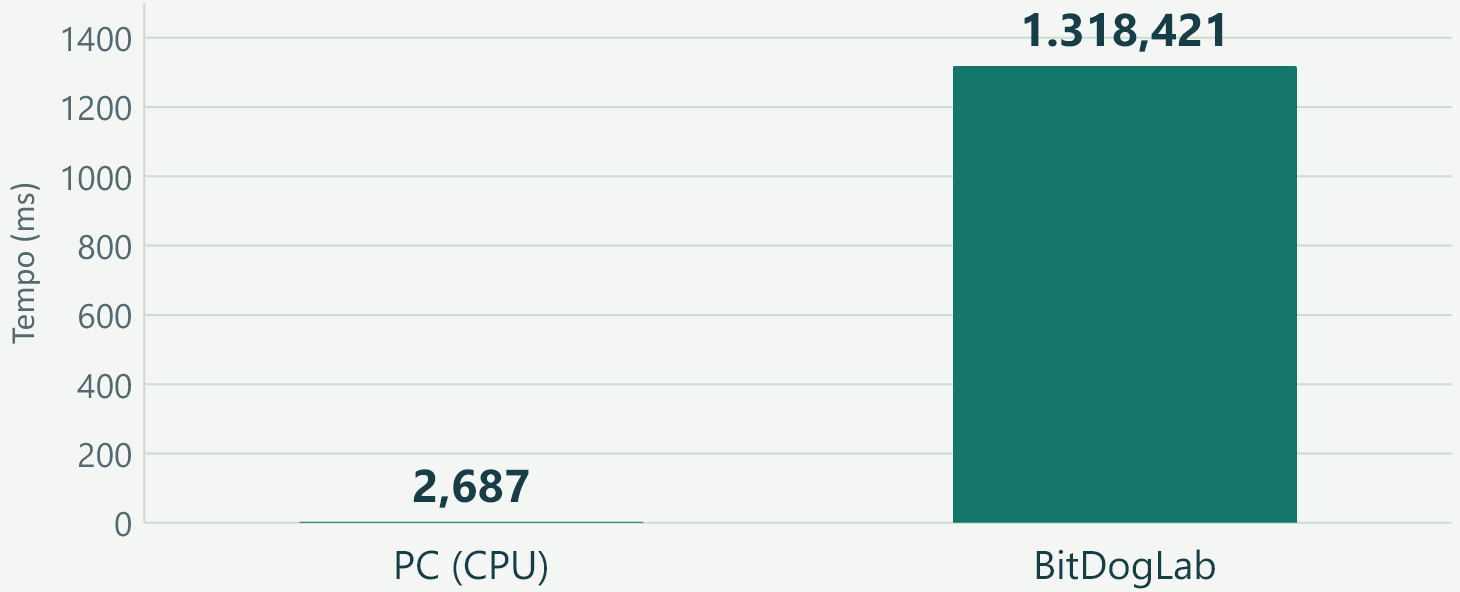
F1 da placa: 0,694, IC95% bootstrap por grupo: 0,526 a 0,829

Tempo no PC e na BitDogLab

Etapa	PC: mediana (ms)	Placa: mediana (ms)
MFE	0,237	1006,545
Inferência	2,425	311,868
Combinado	2,687	1318,421

100 janelas de validação, CPU, uma thread no PC, MFE NumPy versus C++ no RP2040

Tempo combinado no PC e na placa



100

janelas de validação com os mesmos dados PCM

Medianas de MFE + inferência, sem aquisição e USB. A comparação inclui diferenças de implementação

Recursos do firmware científico

Recurso	Tamanho
Modelo INT8	5.264 bytes
Imagem flash do firmware	189.408 bytes
Espaço estático principal de SRAM	186.224 bytes
Pico real de RAM	Ainda não medido

A demo com exemplos e interface usa outro firmware, com tamanho maior

Demonstração com o mesmo arquivo

PAINEL DO COMPUTADOR

Escolher um WAV
Ouvir o trecho
Ver onda, MFE e saída

BITDOGLAB POR USB

Receber os mesmos dados PCM
Executar MFE e rede
Mostrar resultado, LED e bipes

A comparação por USB requer a V3, A mantém os dois exemplos gravados na placa

Microfone: um novo experimento

Áudio reproduzido

Captura de 3 segundos

Classificação experimental

Alto-falante, sala e microfone
alteram o sinal recebido

Resultados ainda precisam de validação acústica

Use uma gravação de origem conhecida, a placa não equivale a um estetoscópio

O que este projeto demonstrou

Inferência local no RP2040

Decisões por grupo iguais à referência no teste

Custos de tempo e memória medidos

Ainda há erros de classificação, diferenças numéricas e ausência de validação clínica/acústica

Referências e dados do experimento

Oliveira et al. (2022)
The CirCor DigiScope Dataset. IEEE JBHI 26(6), 2524–2535
DOI: 10.1109/JBHI.2021.3137048

David et al. (2021)
TensorFlow Lite Micro. Proceedings of MLSys, volume 3
proceedings.mlsys.org

American Heart Association (2026)
Heart Murmurs. Revisão de 17 de março de 2026
heart.org/en/health-topics/heart-murmurs

CirCor 1.0.3 / PhysioNet, relatórios locais, modelo congelado e recibos de compilação